Análisis de Datos y Aprendizaje Máquina con Tensorflow 2.0: Clustering y reducción de dimensionalidad

2019/09/30

Principal Component Analysis (PCA)

Objetivo: Comprender el uso de PCA y aplicarlo a un dataset.

PCA es una técnica de reducción de dimensionalidad que se puede emplear para preprocesamiento y visualización de datos. Se define como una transformación de un espacio vectorial de alta dimensionalidad a un espacio de menor dimensionalidad. Los datos se proyectan en la dirección de máxima varianza, también se buscan las direcciónes donde el error de reconstrucción de los datos es menor.

Si se asume que se tiene una matriz de datos $X \in {}^{n \times d}$ donde $x_i \in \mathbb{R}^d$ La matriz de covarianza de X es $C \in \mathbb{R}^{d \times d}$ y se define por

$$C = \frac{1}{n} \sum_{i=1}^{n} (x_i - \mu)(x_i - \mu)^T$$

donde $\mu \in \mathbb{R}^d$ es la media

$$\mu = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Singular value decomposition (SVD) descompone la matriz A en eigenvectores y una matriz diagonal de valores singulares $\Sigma \in \mathbb{R}^{n \times d}$, donde cada valor sigular está asociado a un eigenvector. En otra forma de mostrar PCA, se descompone la matriz $\frac{1}{n}X^TX$ que es la matriz de covarianza de los datos centrados, donde μ es nulo:

$$A = U\Sigma V^T$$

donde $U \in \mathbb{R}^{n \times n}$ y $V \in \mathbb{R}^{d \times d}$

Si se toman los datos X^TX , se puede mostrar que $A^TA = V\Sigma^2V^T$, donde las columnas de V^T contienen los eigenvectores de X^TX . Los datos transformados a una menor dimensión se obtienen por N = XP donde la matriz $P \in \mathbb{R}^{d \times f}$ contiene f < d eigenvectores de V.

In [1]: import numpy as np
 import pandas as pd
 import matplotlib.pyplot as plt
 %matplotlib inline
 import seaborn as sns

Análisis exploratorio

Etiquetas de clase a valor numérico

- Número de variables y etiquetas
- Valores caracter a numérico

```
In [2]: df = pd.read_csv('iris.csv')
        df.head(10)
Out[2]:
           sepal_length sepal_width petal_length petal_width species
        0
                                3.5
                                              1.4
                   5.1
                                                          0.2 setosa
        1
                   4.9
                                3.0
                                              1.4
                                                          0.2 setosa
        2
                   4.7
                                3.2
                                              1.3
                                                          0.2 setosa
        3
                   4.6
                                3.1
                                              1.5
                                                          0.2 setosa
        4
                   5.0
                                3.6
                                              1.4
                                                          0.2 setosa
        5
                   5.4
                                3.9
                                              1.7
                                                          0.4 setosa
        6
                   4.6
                                3.4
                                                          0.3 setosa
                                              1.4
                                                          0.2 setosa
       7
                   5.0
                                3.4
                                             1.5
        8
                                2.9
                   4.4
                                             1.4
                                                          0.2 setosa
        9
                   4.9
                                3.1
                                              1.5
                                                          0.1 setosa
In [3]: df.tail(10)
Out[3]:
            sepal_length sepal_width petal_length petal_width
                                                                    species
        140
                     6.7
                                  3.1
                                                5.6
                                                             2.4 virginica
        141
                     6.9
                                  3.1
                                                5.1
                                                             2.3 virginica
        142
                     5.8
                                  2.7
                                                5.1
                                                             1.9 virginica
        143
                     6.8
                                  3.2
                                                5.9
                                                             2.3 virginica
        144
                     6.7
                                  3.3
                                                5.7
                                                             2.5 virginica
        145
                     6.7
                                  3.0
                                                5.2
                                                             2.3 virginica
        146
                     6.3
                                  2.5
                                                5.0
                                                             1.9 virginica
                                  3.0
                                                5.2
                                                             2.0 virginica
        147
                     6.5
        148
                     6.2
                                  3.4
                                                5.4
                                                             2.3 virginica
        149
                     5.9
                                  3.0
                                                5.1
                                                             1.8 virginica
In [4]: df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
sepal_length
               150 non-null float64
sepal_width
               150 non-null float64
               150 non-null float64
petal_length
petal_width
               150 non-null float64
               150 non-null object
species
dtypes: float64(4), object(1)
memory usage: 6.0+ KB
```

In [5]: df = df.replace({'setosa':0, 'versicolor':1, 'virginica' :2})

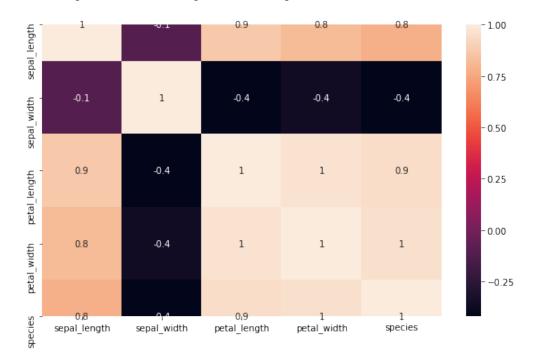
In [6]: df.head(10)

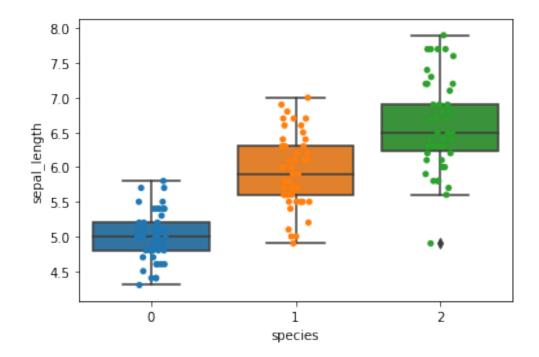
```
Out[6]:
           sepal_length sepal_width petal_length petal_width species
        0
                                   3.5
                                                  1.4
                     5.1
                                                                0.2
                                                                            0
        1
                     4.9
                                   3.0
                                                  1.4
                                                                0.2
                                                                            0
        2
                     4.7
                                   3.2
                                                  1.3
                                                                0.2
                                                                            0
        3
                     4.6
                                                                0.2
                                                                            0
                                   3.1
                                                  1.5
        4
                     5.0
                                   3.6
                                                  1.4
                                                                0.2
                                                                            0
        5
                                                                0.4
                                                                            0
                     5.4
                                   3.9
                                                  1.7
        6
                     4.6
                                   3.4
                                                  1.4
                                                                0.3
                                                                            0
        7
                     5.0
                                   3.4
                                                  1.5
                                                                0.2
                                                                            0
        8
                                                                            0
                     4.4
                                   2.9
                                                  1.4
                                                                0.2
        9
                     4.9
                                                  1.5
                                                                0.1
                                                                            0
```

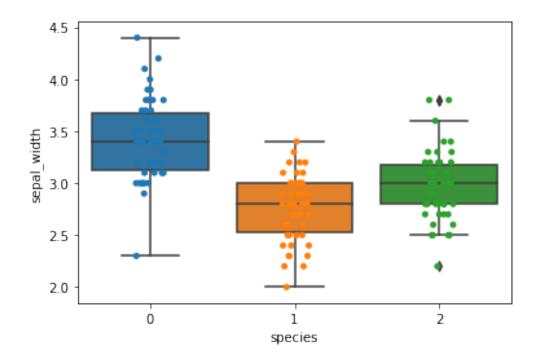
In [7]: df.drop('species', axis=1).head()

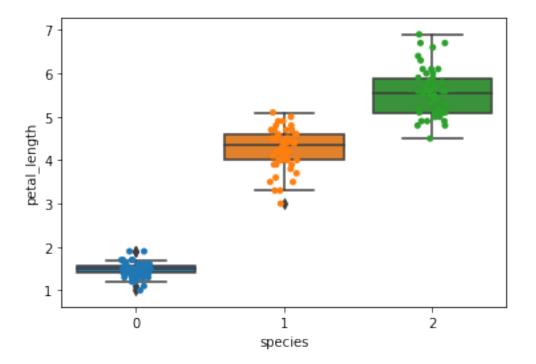
```
Out[7]:
           sepal_length sepal_width petal_length petal_width
        0
                    5.1
                                  3.5
                                                 1.4
                                                              0.2
        1
                    4.9
                                  3.0
                                                 1.4
                                                              0.2
        2
                    4.7
                                  3.2
                                                 1.3
                                                              0.2
        3
                     4.6
                                  3.1
                                                 1.5
                                                              0.2
        4
                    5.0
                                  3.6
                                                              0.2
                                                 1.4
```

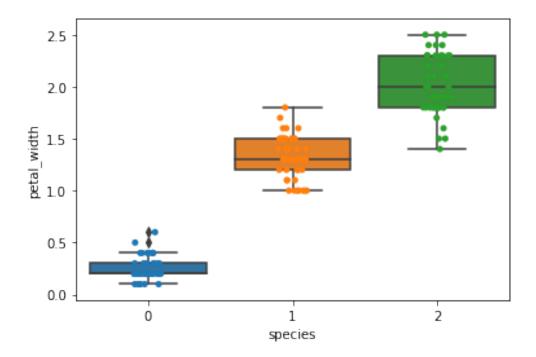
Out[8]: <matplotlib.axes._subplots.AxesSubplot at 0x7f6e30ed2a90>











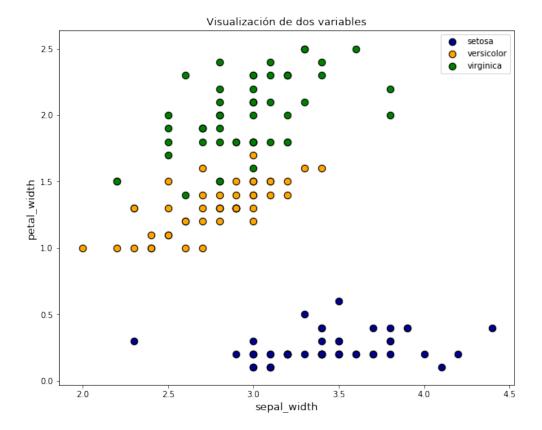
Plot de dos variables en 2d

• Se puede conseguir una mejor visualización con pca

```
In [10]: target_ids = np.unique(df.values[:,-1])
        X_plot = np.concatenate(([df['sepal_width'].values], [df['petal_width'].values]), axis=0
        y = df['species'].values

In [11]: plt.figure(figsize=(10,8))
        colors = ['darkblue', 'orange', 'green']
        target_names = ['setosa', 'versicolor', 'virginica']

for i, c, label in zip(target_ids, colors, target_names):
            plt.scatter(X_plot[0,i == y], X_plot[1,i == y], c = c, edgecolors='black', s=285,laplt.legend()
        plt.title("Visualización de dos variables",fontsize=13)
        plt.xlabel("sepal_width",fontsize=13)
        plt.ylabel("petal_width",fontsize=13)
        plt.show()
```



PCA de sklearn

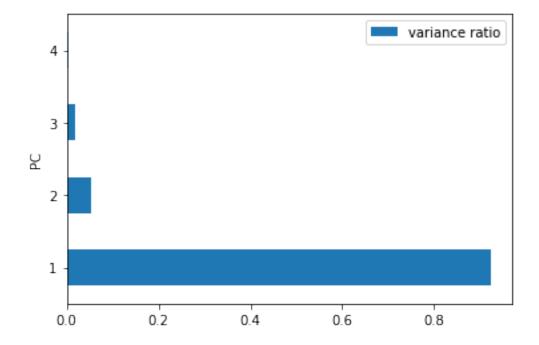
• Se pueden indicar el número de dimensiones con n_components

Varianza de cada PC

 $\bullet~$ Escalando los datos se obtiene un mejor resultado

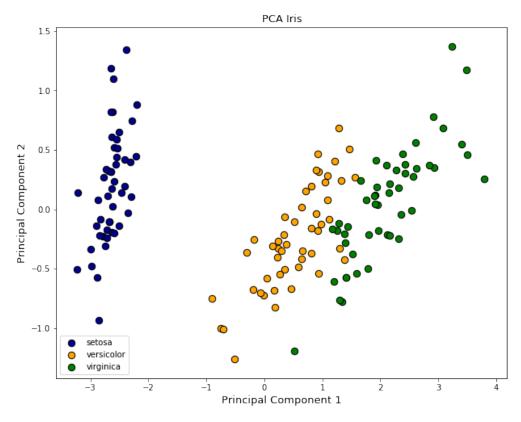
```
In [14]: dfx_pcan.explained_variance_ratio_
Out[14]: array([0.92461621, 0.05301557, 0.01718514, 0.00518309])
In [15]: p_df = pd.DataFrame({'PC':np.arange(1,5), 'variance ratio':dfx_pcan.explained_variance_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_ratio_
```

```
In [16]: ax = p_df.plot.barh('PC')
```



Dos componentes principales

plt.show()

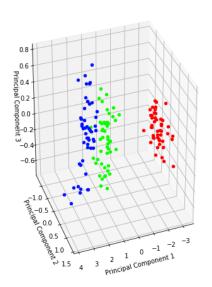


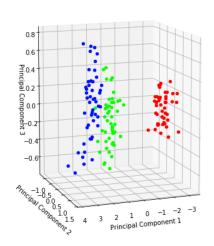
Tres componentes principales

• Con 'Axes3D' se puede visualizar en 3d

In [20]: from mpl_toolkits.mplot3d import Axes3D

```
fig = plt.figure(figsize=(14,8))
ax = fig.add_subplot(1, 2, 1, projection="3d")
for i in range(trans.shape[0]):
    ax.scatter(trans[i, 0], trans[i, 1], trans[i, 2],color=plt.cm.hsv(y[i] / 3.),marker=
ax.view_init(30, 70)
ax.set_xlabel("Principal Component 1")
ax.set_ylabel("Principal Component 2")
ax.set_zlabel("Principal Component 3")
ax = fig.add_subplot(1, 2, 2, projection="3d")
for i in range(trans.shape[0]):
    ax.scatter(trans[i, 0], trans[i, 1], trans[i, 2],color=plt.cm.hsv(y[i] / 3.),marker=
ax.view_init(10, 70)
ax.set_xlabel("Principal Component 1")
ax.set_ylabel("Principal Component 2")
ax.set_zlabel("Principal Component 3")
plt.show()
```





PCA de Breast Cancer

• Visualizar el dataset de los clasificadores anteriores

Out[21]:		diagnosis 1	radius_mean	texture_me	an perimete	r_mean	area_mean	\
	id							
	842302	1	17.99	10.	38	122.80	1001.0	
	842517	1	20.57	17.	77	132.90	1326.0	
	84300903	1 19.69		21.	21.25		1203.0	
	84348301	1	11.42	20.	38	77.58	386.1	
	84358402	1 20.29		14.34		135.10	1297.0	
	843786	1 12.45		15.	15.70		477.1	
	844359	1	18.25	19.	98	119.60	1040.0	
	84458202	1 13.73		20.		90.20	577.9	
	844981	1 13.0		21.82		87.50	519.8	
	84501001	1 12.46		24.04		83.97	475.9	
		. 1	mean compactness_mean			,		
	id	smoothness_n	nean compac	tness_mean	concavity_m	ean \		
842302 842517		0.11	840	0.27760	0.30	010		
		0.08474		0.07864 0.08				
	84300903			0.15990	0.19			
	84348301	0.14250		0.28390	0.13			
	84358402	0.14230		0.13280	0.19			
	843786	0.12780		0.13280	0.15			
	844359			0.17000	0.13			
		0.09463						
	84458202	0.11890		0.16450	0.09			
	844981	0.12730 0.11860			0.19320 0.18590 0.23960 0.22730			
	84501001	0.11	1860	0.23960	0.22	730		
		concave poir	nts_mean sy	mmetry_mean	textu	re_worst	\	
	id							
842302			0.14710	0.2419		17.33		
	842517 0.07017		0.07017	0.1812		23.41		
	84300903	0.12790		0.2069		25.53		
	84348301	0.10520		0.2597		26.50		
	84358402	0.10430			0.1809 1			
	843786	0.08089		0.2087		23.75		
	844359	0.07400		0.1794		27.66		
	84458202	0.05985 0.09353 0.08543		0.2196		28.14		
	844981			0.2350		30.73		
	84501001			0.2030		40.68		
								,
		perimeter_wo	orst area_w	vorst smoot	hness_worst	compact	ness_worst	\
	id	40	1 60 00	110.0	0 4000		0 0050	
	842302			019.0	0.1622		0.6656	
	842517			956.0	0.1238		0.1866	
	84300903			709.0	0.1444		0.4245	
	84348301			567.7	0.2098		0.8663	
	84358402			575.0	0.1374		0.2050	
	843786			741.6	0.1791		0.5249	
	844359			306.0	0.1442		0.2576	
	84458202	110).60 8	397.0	0.1654		0.3682	

```
84501001
                             97.65
                                          711.4
                                                           0.1853
                                                                               1.0580
                   concavity_worst
                                    concave points_worst symmetry_worst \
         id
         842302
                            0.7119
                                                   0.2654
                                                                    0.4601
         842517
                            0.2416
                                                   0.1860
                                                                    0.2750
         84300903
                            0.4504
                                                   0.2430
                                                                    0.3613
         84348301
                            0.6869
                                                   0.2575
                                                                    0.6638
         84358402
                            0.4000
                                                   0.1625
                                                                    0.2364
         843786
                            0.5355
                                                   0.1741
                                                                    0.3985
         844359
                            0.3784
                                                   0.1932
                                                                    0.3063
         84458202
                            0.2678
                                                   0.1556
                                                                    0.3196
         844981
                            0.5390
                                                   0.2060
                                                                    0.4378
         84501001
                                                   0.2210
                            1.1050
                                                                    0.4366
                   fractal_dimension_worst Unnamed: 32
         id
         842302
                                    0.11890
                                                     NaN
         842517
                                    0.08902
                                                     NaN
                                                     NaN
         84300903
                                    0.08758
         84348301
                                    0.17300
                                                     NaN
         84358402
                                    0.07678
                                                     NaN
                                                     NaN
         843786
                                    0.12440
         844359
                                    0.08368
                                                     NaN
         84458202
                                    0.11510
                                                     NaN
                                    0.10720
                                                     NaN
         844981
         84501001
                                    0.20750
                                                     NaN
         [10 rows x 32 columns]
In [22]: y = df['diagnosis']
         X = df.drop(['diagnosis','Unnamed: 32'],axis=1)
         dfx = pd.DataFrame(data=X,columns=df.columns[1:31])
         dfx.tail()
Out[22]:
                 radius_mean texture_mean perimeter_mean area_mean smoothness_mean \
         id
         926424
                       21.56
                                      22.39
                                                     142.00
                                                                 1479.0
                                                                                 0.11100
         926682
                       20.13
                                      28.25
                                                     131.20
                                                                 1261.0
                                                                                 0.09780
                       16.60
                                      28.08
                                                                                 0.08455
         926954
                                                     108.30
                                                                 858.1
         927241
                       20.60
                                      29.33
                                                     140.10
                                                                 1265.0
                                                                                 0.11780
         92751
                        7.76
                                      24.54
                                                      47.92
                                                                  181.0
                                                                                 0.05263
                 compactness_mean concavity_mean concave points_mean symmetry_mean \
         id
         926424
                          0.11590
                                           0.24390
                                                                 0.13890
                                                                                 0.1726
         926682
                          0.10340
                                           0.14400
                                                                 0.09791
                                                                                 0.1752
                                           0.09251
         926954
                          0.10230
                                                                0.05302
                                                                                 0.1590
         927241
                          0.27700
                                           0.35140
                                                                0.15200
                                                                                 0.2397
```

739.3

0.1703

0.5401

844981

106.20

```
id
                                                                      26.40
         926424
                                 0.05623
                                                     25.450
         926682
                                 0.05533
                                                     23.690
                                                                      38.25
         926954
                                 0.05648
                                                     18.980
                                                                      34.12
                                          . . .
         927241
                                 0.07016
                                                     25.740
                                                                      39.42
                                          . . .
         92751
                                 0.05884
                                                      9.456
                                                                      30.37
                                          . . .
                 perimeter_worst area_worst smoothness_worst compactness_worst \
         id
         926424
                          166.10
                                       2027.0
                                                        0.14100
                                                                            0.21130
         926682
                           155.00
                                       1731.0
                                                        0.11660
                                                                            0.19220
         926954
                          126.70
                                       1124.0
                                                        0.11390
                                                                            0.30940
         927241
                          184.60
                                       1821.0
                                                        0.16500
                                                                            0.86810
         92751
                           59.16
                                        268.6
                                                        0.08996
                                                                            0.06444
                 concavity_worst concave points_worst symmetry_worst \
         id
         926424
                          0.4107
                                                 0.2216
                                                                  0.2060
         926682
                          0.3215
                                                 0.1628
                                                                  0.2572
         926954
                          0.3403
                                                 0.1418
                                                                  0.2218
         927241
                          0.9387
                                                 0.2650
                                                                  0.4087
                          0.0000
                                                 0.0000
                                                                  0.2871
         92751
                 {\tt fractal\_dimension\_worst}
         id
         926424
                                  0.07115
         926682
                                  0.06637
         926954
                                  0.07820
         927241
                                  0.12400
         92751
                                  0.07039
         [5 rows x 30 columns]
In [23]: X_plot = np.concatenate(([df['symmetry_worst'].values], [df['compactness_worst'].values]
         y = df['diagnosis'].values
         plt.figure(figsize=(10,8))
         colors = ['darkblue','orange']
         target_names = ['benign', 'malignant']
         for i, c, label in zip(target_ids, colors, target_names):
             plt.scatter(X_plot[0,i == y], X_plot[1,i == y], c = c, edgecolors='black', s=285,la
         plt.legend()
         plt.title("Visualización de dos variables",fontsize=13)
         plt.xlabel("symmetry_worst",fontsize=13)
         plt.ylabel("compactness_worst",fontsize=13)
         plt.show()
```

0.00000

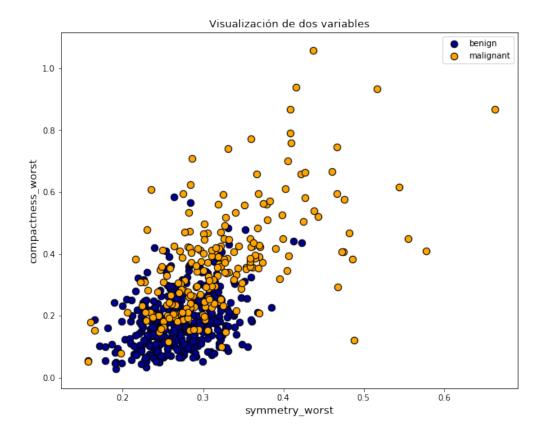
fractal_dimension_mean ... radius_worst texture_worst \

0.00000

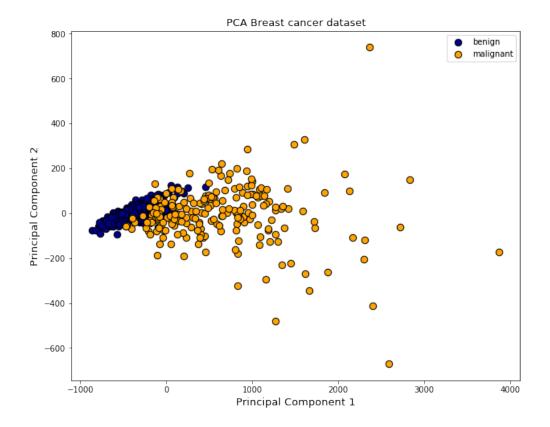
0.1587

92751

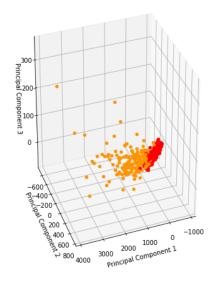
0.04362

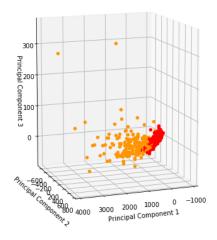


• Con PCA es más clara la separación de clases



```
In [26]: fig = plt.figure(figsize=(14,8))
       ax = fig.add_subplot(1, 2, 1, projection="3d")
       for i in range(trans.shape[0]):
           ax.view_init(30, 70)
       ax.set_xlabel("Principal Component 1")
       ax.set_ylabel("Principal Component 2")
       ax.set_zlabel("Principal Component 3")
       ax = fig.add_subplot(1, 2, 2, projection="3d")
       for i in range(trans.shape[0]):
           ax.scatter(trans[i, 0], trans[i, 1], trans[i, 2],color=plt.cm.hsv(y[i] / 10.),marker
       ax.view_init(10, 70)
       ax.set_xlabel("Principal Component 1")
       ax.set_ylabel("Principal Component 2")
       ax.set_zlabel("Principal Component 3")
       plt.show()
```



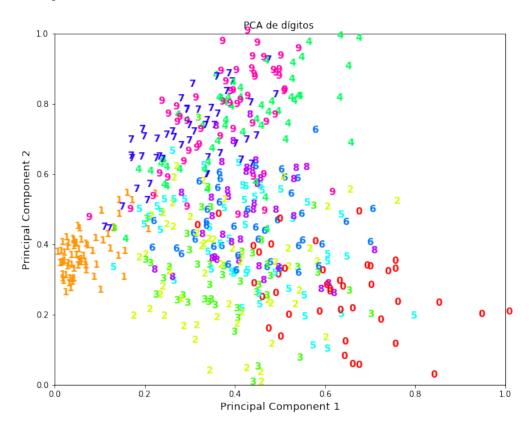


Visualizar dígitos

- El número de clases es mayor
- Se visualizan los pixeles de dígitos en 2 dimensiones

 $https://scikit-learn.org/stable/auto_examples/manifold/plot_lle_digits.html\\$

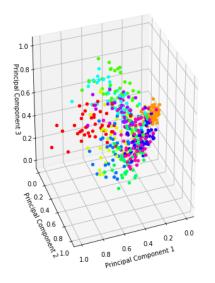
• Solo algunos elementos

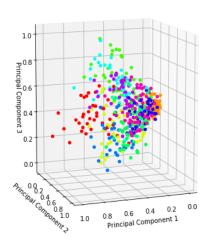


Tres componentes principales

```
ax.set_xlabel("Principal Component 1")
ax.set_ylabel("Principal Component 2")
ax.set_zlabel("Principal Component 3")

ax = fig.add_subplot(1, 2, 2, projection="3d")
for i in range(X.shape[0]):
    ax.scatter(X[i, 0], X[i, 1], X[i, 2],color=plt.cm.hsv(y[i] / 10.),marker='o')
ax.view_init(10, 70)
ax.set_xlabel("Principal Component 1")
ax.set_ylabel("Principal Component 2")
ax.set_zlabel("Principal Component 3")
plt.show()
```





- Se obtiene una visualización de datos de alta dimensión
- Probar PCA con diferentes datasets, después aplicar clasificación