# Análisis de Datos y Aprendizaje Máquina con Tensorflow 2.0: Perceptrón Multicapa

2019/09/30

# Inicialización y no-linearidad

Objetivo: Conocer los diferentes inicializadores, funciones de costo y activación.

- La inicialización de pesos tiene efecto en el tiempo de entrenamiento
- Las funciones de costo dependen de el número de clases o si es clasificación o regresión
- Las funciones no lineales tienen diferentes comportamientos en los tipos de redes, estas proyectan los datos a un diferente espacio

#### Leer conjunto de datos

(381,)

```
In [1]: import matplotlib.pyplot as plt
        import tensorflow as tf
        from tensorflow import keras
        from tensorflow.keras.layers import BatchNormalization, Activation
        from tensorflow.keras.models import Sequential
        from tensorflow.keras.layers import Dense
        from tensorflow.keras import backend as K
        K.clear_session()
        from sklearn.datasets import load_breast_cancer
        from sklearn.model_selection import train_test_split
        data = load_breast_cancer()
        X_data = data.data
        y_data = data.target
        x_train, x_test, y_train, y_test = train_test_split(X_data, y_data, test_size = 0.33, ran
In [2]: print(x_train.shape)
        print(y_train.shape)
        print(x_test.shape)
       print(y_test.shape)
(381, 30)
```

```
(188, 30)
(188,)
```

• Se modifica la forma de los datos de 2-d (n, 28, 28) a 1-d (n, 784)

## Modelo MLP simple, se aplica optimizador 'rmsprp'

• En el ejemplo anterior 'SGD' tiene un desempeño bajo

```
In [3]: epoch = 50
     verbose = 0
     batch = 50

In [4]: from tensorflow.keras.models import Sequential
     from tensorflow.keras.layers import Dense
```

#### **Funcion costo**

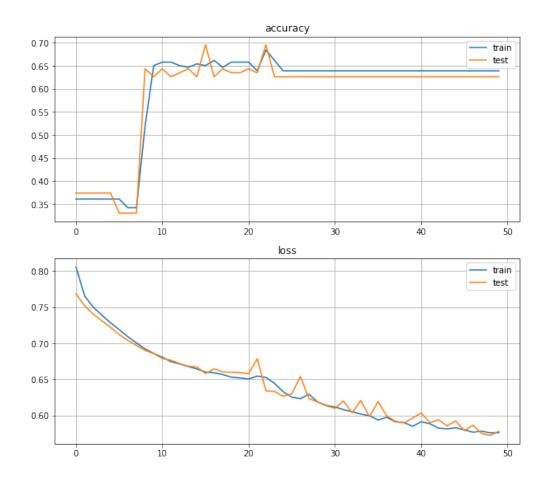
• Se mide que tan lejos esta  $\hat{y_i}$  de  $y_i$ 

$$MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

- Para más de 2 clases se usa 'sparse\_categorical\_crossentropy'
- Para más de 2 clases con 'one hot' se aplica 'categorical\_crossentropy'
- Para 2 clases 'binary\_crossentropy'

```
In [5]: def make_model():
         model = Sequential()
         model.add(Dense(16, input_shape = (30, ), activation = 'sigmoid'))
         model.add(Dense(1, activation = 'sigmoid'))
         model.compile(optimizer='rmsprop', loss='binary_crossentropy',
                     metrics=['accuracy'])
         return model
In [6]: model = make_model()
      model.summary()
Model: "sequential"
Layer (type) Output Shape
Layer (type)
_____
dense (Dense)
                       (None, 16)
                                            496
dense_1 (Dense)
                       (None, 1)
```

```
_____
Total params: 513
Trainable params: 513
Non-trainable params: 0
_____
In [7]: history = model.fit(x_train, y_train, batch_size = batch, validation_split = 0.3,
                       epochs = epoch, verbose = verbose)
In [8]: #plot
      plt.figure(figsize=(10,9))
      plt.subplot(211)
      plt.plot(history.history['accuracy'])
      plt.plot(history.history['val_accuracy'])
      plt.title('accuracy')
      plt.legend(['train', 'test'])
      plt.grid()
      plt.subplot(212)
      plt.plot(history.history['loss'])
      plt.plot(history.history['val_loss'])
      plt.title('loss')
      plt.legend(['train', 'test'])
      plt.grid()
```



# No-linearidad (Función de activación)

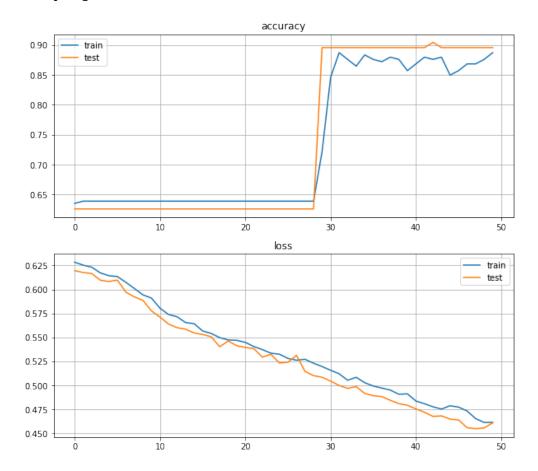
- Las funciones no-lineales son necesarias en los perceptrones multicapa, estas mapean las salidas de las multiplicaciones por las matrices a un espacio no lineal en donde los datos pueden ser clasificados.
- Existen muchas funciones de activación como:
  - -Relu $\max(0,1)$  que trabaja bien con imágenes y muestra una rápida convergencia que las demás funciones

- Tanh tanh(x) que tiene una salida de un rango de -1 a 1, a diferencia de la sigmoide
- Investigar el probelma del gradiente y el efecto de las funciones de activación

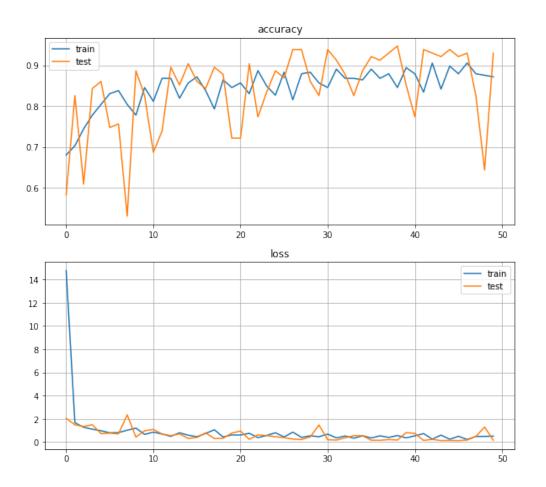
#### tanh

```
In [10]: def make model():
          model = Sequential()
          model.add(Dense(16, input_shape = (30, ), activation = 'tanh'))
          model.add(Dense(1, activation = 'sigmoid'))
          model.compile(optimizer='rmsprop', loss='binary_crossentropy',
                      metrics=['accuracy'])
          return model
In [11]: model = make_model()
       model.summary()
Model: "sequential_1"
 ayer (type) Output Shape Param #
Layer (type)
______
dense_2 (Dense)
                      (None, 16)
                                            496
dense_3 (Dense)
                (None, 1)
                                           17
______
Total params: 513
Trainable params: 513
Non-trainable params: 0
______
In [12]: history = model.fit(x_train, y_train, batch_size = batch, validation_split = 0.3,
                       epochs = epoch, verbose = verbose)
In [13]: #plot
       plt.figure(figsize=(10,9))
       plt.subplot(211)
       plt.plot(history.history['accuracy'])
       plt.plot(history.history['val_accuracy'])
       plt.title('accuracy')
       plt.legend(['train', 'test'])
       plt.grid()
       plt.subplot(212)
       plt.plot(history.history['loss'])
       plt.plot(history.history['val_loss'])
       plt.title('loss')
```

```
plt.legend(['train', 'test'])
plt.grid()
```



```
model.add(Dense(1, activation = 'sigmoid'))
          model.compile(optimizer='rmsprop', loss='binary_crossentropy',
                      metrics=['accuracy'])
           return model
In [16]: model = make_model()
       model.summary()
Model: "sequential_2"
Layer (type) Output Shape Param #
_____
dense 4 (Dense)
                       (None, 16)
dense_5 (Dense) (None, 1) 17
______
Total params: 513
Trainable params: 513
Non-trainable params: 0
In [17]: history = model.fit(x_train, y_train, batch_size = batch, validation_split = 0.3,
                        epochs = epoch, verbose = verbose)
In [18]: #plot
       plt.figure(figsize=(10,9))
       plt.subplot(211)
       plt.plot(history.history['accuracy'])
       plt.plot(history.history['val_accuracy'])
       plt.title('accuracy')
       plt.legend(['train', 'test'])
       plt.grid()
       plt.subplot(212)
       plt.plot(history.history['loss'])
       plt.plot(history.history['val_loss'])
       plt.title('loss')
       plt.legend(['train', 'test'])
       plt.grid()
```

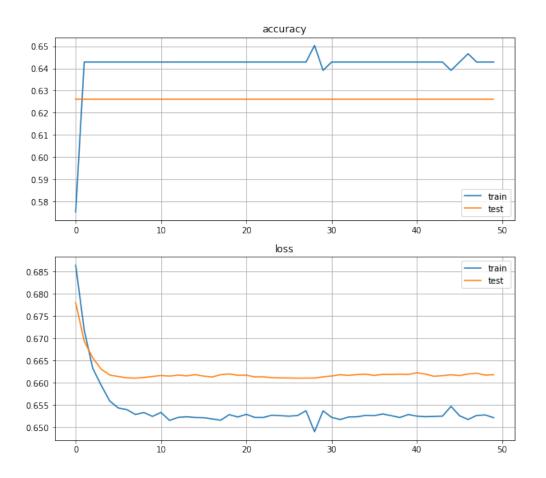


# Inicialización de pesos

### $he\_normal$

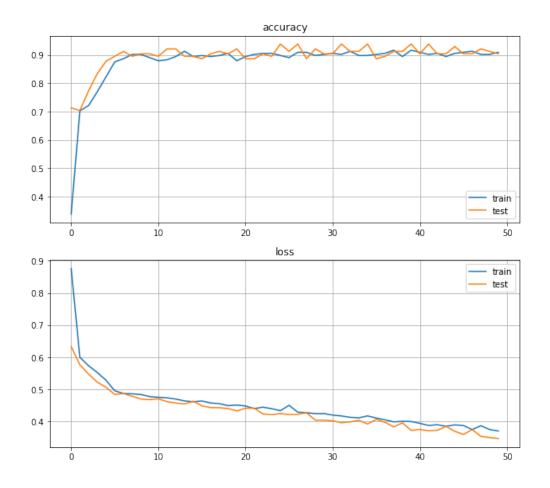
• he\_normal muestrea de una distribución normal centrada con stddev =  $\operatorname{sqrt}(2 / \operatorname{fan_in})$  donde fan\_in es el número de entradas en el tensor de pesos.

```
model.add(Dense(16, input_shape = (30, ), activation = 'tanh', kernel_initializer='!
           model.add(Dense(1, activation = 'sigmoid'))
           model.compile(optimizer='rmsprop', loss='binary_crossentropy',
                      metrics=['accuracy'])
           return model
In [21]: model = make_model()
       model.summary()
Model: "sequential 3"
Layer (type) Output Shape Param #
_____
dense 6 (Dense)
                       (None, 16)
                                              496
dense_7 (Dense) (None, 1) 17
______
Total params: 513
Trainable params: 513
Non-trainable params: 0
In [22]: history = model.fit(x_train, y_train, batch_size = batch, validation_split = 0.3,
                        epochs = epoch, verbose = verbose)
In [23]: #plot
       plt.figure(figsize=(10,9))
       plt.subplot(211)
       plt.plot(history.history['accuracy'])
       plt.plot(history.history['val_accuracy'])
       plt.title('accuracy')
       plt.legend(['train', 'test'])
       plt.grid()
       plt.subplot(212)
       plt.plot(history.history['loss'])
       plt.plot(history.history['val_loss'])
       plt.title('loss')
       plt.legend(['train', 'test'])
       plt.grid()
```



### orthogonal

```
model.compile(optimizer='rmsprop', loss='binary_crossentropy',
                      metrics=['accuracy'])
          return model
In [26]: model = make_model()
       model.summary()
Model: "sequential_4"
Layer (type) Output Shape Param #
Layer (type)
_____
dense_8 (Dense) (None, 16)
                                            496
dense_9 (Dense) (None, 1) 17
______
Total params: 513
Trainable params: 513
Non-trainable params: 0
In [27]: history = model.fit(x_train, y_train, batch_size = batch, validation_split = 0.3,
                       epochs = epoch, verbose = verbose)
In [28]: #plot
       plt.figure(figsize=(10,9))
       plt.subplot(211)
       plt.plot(history.history['accuracy'])
       plt.plot(history.history['val_accuracy'])
       plt.title('accuracy')
       plt.legend(['train', 'test'])
       plt.grid()
       plt.subplot(212)
       plt.plot(history.history['loss'])
       plt.plot(history.history['val_loss'])
       plt.title('loss')
       plt.legend(['train', 'test'])
       plt.grid()
```



Test accuracy: 0.9255319

- La red a mejorado el desempeño
- Probar con diferentes capas y funciones de activación
- Mejorar el tiempo de entrenamiento de la red y 'Test accuracy'