# Análisis de Datos y Aprendizaje Máquina con Tensorflow 2.0: Redes neuronales recurrentes

2019/09/30

#### 1 Estructura RNN

- Objetivo: Conocer la notación de las RNN
- Las redes recurrentes (RNN), son un tipo de red neuronal que procesa secuencialmente los datos, tomando en cuenta el estado oculto anterior  $h_{t-1}$  en la instancia de tiempo t
- Muchas RNN trabajan con embeddings en las entradas. Los embeddings son representaciones vectoriales aprendidas por la red, lo cual captura la relación de las palabras.
- A diferencia de los MLP, las RNN tienen memoria, es por eso que estas redes trabajan bien con secuencias de datos (el texto puede considerarse como una secuencia de datos)

```
In [1]: from tensorflow.keras.models import Model
    from tensorflow.keras.layers import LSTM, Embedding, Dense, SimpleRNN
    from tensorflow.keras.datasets import imdb
    from tensorflow.keras.models import Sequential

from tensorflow.keras.preprocessing.sequence import pad_sequences
    import matplotlib.pyplot as plt
```

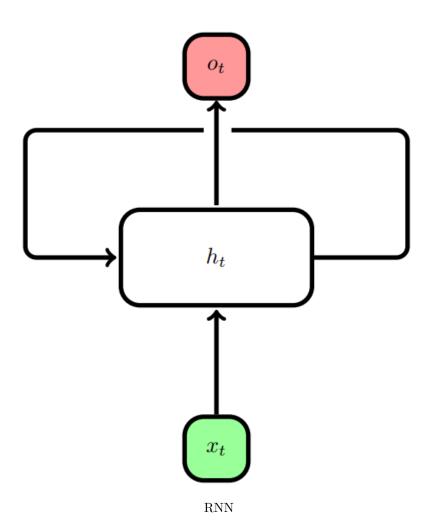
## 2 Reseñas de películas de IMDB

- Conjunto de datos de 25,000 críticas de películas de IMDB, etiquetadas por sentimiento (positivo / negativo).
- La función 'pad\_sequences' recibe padding = 'post'/'pre' para agregar '0'. Por defecto se toma el parámetro 'pre'

https://www.tensorflow.org/guide/keras/masking\_and\_padding

```
In [2]: # numero de palabras
    num_words = 4000

max_len = 100
```



```
(x_train, y_train), (x_test, y_test) = imdb.load_data(num_words=num_words)

x_train = pad_sequences(x_train, maxlen=max_len, padding = 'post')

x_test = pad_sequences(x_test, maxlen=max_len, padding = 'post')

print(x_train.shape)
print(x_test.shape)
print(y_train.shape)
print(y_train.shape)
print(y_test.shape)

(25000, 100)
(25000,)
(25000,)

In [3]: epoch = 10
verbose = 1
batch = 30
```

#### 2.1 Cada palabra de la review esta identificada por un número

```
In [4]: print('Reseña')
       print(x_train[0])
       print('Etiqueta')
       print(y_train[0])
Reseña
[1415
       33
             6
                 22
                      12 215
                                28
                                    77
                                          52
                                                5
                                                    14 407
                                                              16
                                                                  82
   2
        8
             4 107
                    117
                          2
                                15
                                    256
                                          4
                                                2
                                                    7 3766
                                                              5
                                                                 723
  36
       71
            43 530 476
                          26 400 317
                                                7
                                                          2 1029
                                                                  13
                                          46
                                                    4
 104
             4 381
                          297
                                    32 2071
                                                    26 141
                                                              6 194
       88
                      15
                                98
                                               56
                226
                      22
   2
       18
             4
                           21
                               134
                                    476
                                              480
                                                    5 144
                                                                   2
                                          26
                                                              30
  18
       51
            36
                 28
                     224
                           92
                                25
                                    104
                                          4
                                              226
                                                    65
                                                        16
                                                             38 1334
  88
       12
            16
                283
                       5
                           16
                                 2 113 103
                                               32
                                                    15
                                                        16
                                                                  19
 178
       32]
Etiqueta
```

#### 2.2 Palabras de reseña

```
In [5]: wordDict = {y:x for x,y in imdb.get_word_index().items()}
    res = []
    for index in x_train[0]:
        res.append(wordDict.get(index - 3))
    print('Reseña: ',res,'Longitud reseña: ', len(res))

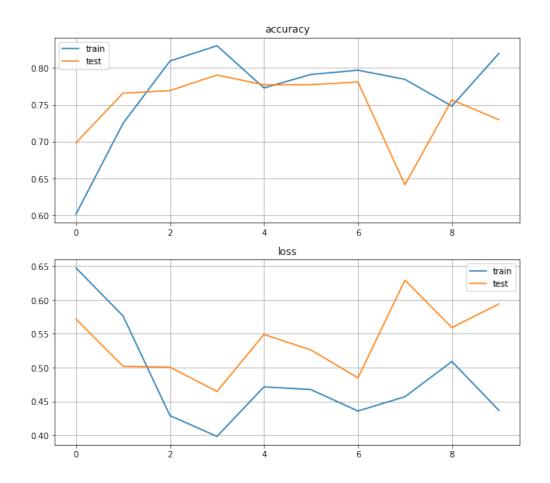
Reseña: ['cry', 'at', 'a', 'film', 'it', 'must', 'have', 'been', 'good', 'and', 'this', 'definit'
```

#### 2.3 RNN simple con embedding

• Los embeddings son representaciones vectoriales de palabras o caracteres

```
In [6]: model = Sequential()
   model.add(Embedding(num_words, 128))
   model.add(SimpleRNN(128))
   model.add(Dense(1, activation='sigmoid'))
In [7]: model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
   model.summary()
   history = model.fit(x_train, y_train, batch_size=batch, epochs=epoch, verbose = verbose,
             validation_split = 0.3)
Model: "sequential"
Layer (type)
             Output Shape
                         Param #
_____
embedding (Embedding) (None, None, 128)
                         512000
simple_rnn (SimpleRNN) (None, 128)
                          32896
dense (Dense) (None, 1) 129
_____
Total params: 545,025
Trainable params: 545,025
Non-trainable params: 0
Train on 17500 samples, validate on 7500 samples
Epoch 1/10
Epoch 2/10
Epoch 3/10
Epoch 4/10
Epoch 5/10
17500/17500 [============== ] - 27s 2ms/sample - loss: 0.4714 - accuracy: 0.7730 -
Epoch 6/10
Epoch 7/10
Epoch 8/10
Epoch 9/10
Epoch 10/10
17500/17500 [===========] - 27s 2ms/sample - loss: 0.4366 - accuracy: 0.8199 -
```

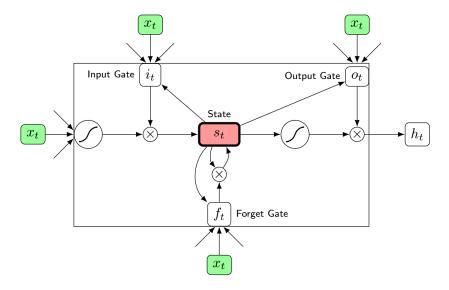
```
In [8]: test_loss, test_acc = model.evaluate(x_test, y_test, verbose=2)
        print('\nTest acccuracy:', test_acc)
25000/1 - 7s - loss: 0.7967 - accuracy: 0.7376
Test acccuracy: 0.73756
In [9]: plt.figure(figsize=(10,9))
        plt.subplot(211)
        plt.plot(history.history['accuracy'])
        plt.plot(history.history['val_accuracy'])
        plt.title('accuracy')
        plt.legend(['train', 'test'])
       plt.grid()
        plt.subplot(212)
        plt.plot(history.history['loss'])
        plt.plot(history.history['val_loss'])
        plt.title('loss')
        plt.legend(['train', 'test'])
        plt.grid()
```



Test acccuracy: 0.73756

### 2.4 LSTM

- $\bullet\,$  En LSTM se toma en cuenta el estado  $s_t,$  el cual sirve para olvidar o recordar elementos relevantes
- Las LSTM cuentan con más matrices, lo que les permite tener mejor memoria



```
In [11]: model = Sequential()
         model.add(Embedding(num_words, 128))
         model.add(LSTM(128))
         model.add(Dense(1, activation='sigmoid'))
In [12]: model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
         model.summary()
```

history = model.fit(x\_train, y\_train, batch\_size=batch, epochs=epoch, verbose = verbose, validation\_split = 0.3)

Model: "sequential\_1"

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, None, 128)	512000
lstm (LSTM)	(None, 128)	131584
dense_1 (Dense)	(None, 1)	129

Total params: 643,713 Trainable params: 643,713 Non-trainable params: 0

Train on 17500 samples, validate on 7500 samples

Epoch 1/10

17500/17500 [===========] - 11s 628us/sample - loss: 0.4699 - accuracy: 0.7717

Epoch 2/10

17500/17500 [===========] - 9s 524us/sample - loss: 0.3360 - accuracy: 0.8634

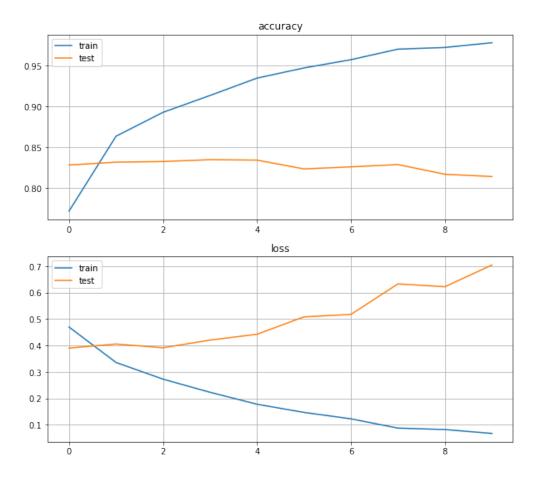
Epoch 3/10

```
Epoch 4/10
Epoch 5/10
Epoch 6/10
Epoch 7/10
17500/17500 [============] - 9s 510us/sample - loss: 0.1226 - accuracy: 0.9571
Epoch 8/10
17500/17500 [==============] - 9s 518us/sample - loss: 0.0876 - accuracy: 0.9700
Epoch 9/10
17500/17500 [===========] - 9s 522us/sample - loss: 0.0820 - accuracy: 0.9721
Epoch 10/10
In [14]: plt.figure(figsize=(10,9))
     plt.subplot(211)
     plt.plot(history.history['accuracy'])
     plt.plot(history.history['val_accuracy'])
     plt.title('accuracy')
     plt.legend(['train', 'test'])
     plt.grid()
     plt.subplot(212)
     plt.plot(history.history['loss'])
     plt.plot(history.history['val_loss'])
```

plt.title('loss')

plt.grid()

plt.legend(['train', 'test'])



Test acccuracy: 0.81608

- Experimentar con diferentes arquitecturas y número de neuronas
- Modificar el dataset para obtener mejores resultados
- Experimentar con otro dataset
- Experimentar con otros optimizadores y funciones de activación
- Nota: Los parámetros 'num\_words' y 'maxlen' pueden dar como resultados diferentes entrenamientos, al modificar la estructura del dataset