# Análisis de Datos y Aprendizaje Máquina con Tensorflow 2.0: Redes neuronales recurrentes

## 2019/09/30

#### Estructura RNN

- Objetivo: Conocer la notación de las RNN
- RNN son estructuras que pueden manejar datos con formato "secuencial" al preservar el "estado" anterior
- Muchas RNN trabajan con embeddings en las entradas. Los embeddings son representaciones vectoriales aprendidas por la red, lo cual captura la relación de las palabras.
- A diferencia de las Feedforward neural networks, las RNN pueden manejar secuencias de datos

```
In [8]: from tensorflow.keras.models import Model
from tensorflow.keras.layers import LSTM, Embedding, Dense, SimpleRNN
from tensorflow.keras.datasets import imdb
from tensorflow.keras.models import Sequential

from tensorflow.keras.preprocessing.sequence import pad_sequences
import matplotlib.pyplot as plt
```

# Reseñas de películas de IMDB


• Conjunto de datos de 25,000 críticas de películas de IMDB, etiquetadas por sentimiento (positivo / negativo).

```
In [9]: # numero de palabras
    num_words = 10000

maxlen = 59

(x_train, y_train), (x_test, y_test) = imdb.load_data(num_words=num_words)

x_train = pad_sequences(x_train, maxlen=maxlen)
```



RNN

```
x_test = pad_sequences(x_test, maxlen=maxlen)

print(x_train.shape)
    print(y_train.shape)
    print(y_train.shape)
    print(y_test.shape)

(25000, 59)
(25000,)
(25000,)
(25000,)
In [10]: epoch = 10
    verbose = 1
    batch = 30
```

#### Cada palabra de la review esta identificada por un número

```
In [11]: print('Reseña')
        print(x_train[0])
        print('Etiqueta')
        print(y_train[0])
Reseña
[ 13 104
                         15 297
           88
                 4 381
                                  98
                                       32 2071
                                                56
                                                     26 141
                                                               6
 194 7486
           18
                4 226
                        22
                              21 134
                                      476
                                            26
                                               480
                                                     5 144
                                                              30
5535
       18
           51
                36
                   28
                        224
                              92
                                  25 104
                                            4 226
                                                     65
                                                         16
                                                              38
1334
       88
           12
                16 283
                        5
                            16 4472 113 103
                                                32
                                                     15
                                                        16 5345
  19 178
           32]
Etiqueta
```

#### Palabras de reseña

```
In [12]: wordDict = {y:x for x,y in imdb.get_word_index().items()}
    res = []
    for index in x_train[0]:
        res.append(wordDict.get(index - 3))
        print('Reseña: ',res,'Longitud reseña: ', len(res))
Reseña: ['i', 'think', 'because', 'the', 'stars', 'that', 'play', 'them', 'all', 'grown', 'up',
```

## RNN simple con embedding

 $\bullet\,$  Los embeddings son representaciones vectoriales de palabras o caracteres

```
In [13]: model = Sequential()
    model.add(Embedding(num_words, 128))
    model.add(SimpleRNN(128))
    model.add(Dense(1, activation='sigmoid'))
In [14]: model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
    model.summary()
    history = model.fit(x_train, y_train, batch_size=batch, epochs=epoch, verbose = verbose,
              validation_split = 0.3)
Model: "sequential 1"
        Output Shape Param #
Layer (type)
______
embedding_1 (Embedding)
             (None, None, 128)
                            1280000
simple_rnn_1 (SimpleRNN) (None, 128)
                            32896
dense_1 (Dense) (None, 1)
______
Total params: 1,313,025
Trainable params: 1,313,025
Non-trainable params: 0
Train on 17500 samples, validate on 7500 samples
Epoch 1/10
Epoch 2/10
Epoch 3/10
Epoch 4/10
17500/17500 [===========] - 23s 1ms/sample - loss: 0.1517 - accuracy: 0.9433 -
Epoch 5/10
Epoch 6/10
Epoch 7/10
Epoch 8/10
Epoch 9/10
17500/17500 [===========] - 22s 1ms/sample - loss: 0.0751 - accuracy: 0.9725 -
Epoch 10/10
In [15]: test_loss, test_acc = model.evaluate(x_test, y_test, verbose=2)
    print('\nTest acccuracy:', test acc)
```


```
25000/1 - 5s - loss: 1.3845 - accuracy: 0.7146
Test acccuracy: 0.71464
In [16]: plt.figure(figsize=(10,9))
         plt.subplot(211)
         plt.plot(history.history['accuracy'])
         plt.plot(history.history['val_accuracy'])
         plt.title('accuracy')
         plt.legend(['train', 'test'])
         plt.grid()
         plt.subplot(212)
         plt.plot(history.history['loss'])
         plt.plot(history.history['val_loss'])
         plt.title('loss')
         plt.legend(['train', 'test'])
         plt.grid()
                                         accuracy
     1.00
             train
             test
     0.95
     0.90
     0.85
     0.80
     0.75
     0.70
     0.65
                                           loss
              train
              test
      1.0
      0.8
      0.6
      0.4
```

0.0

#### LSTM


In [18]: model = Sequential()

- $\bullet\,$  En LSTM se toma en cuenta el estado st, el cual sirve para olvidar o recordar parámetros relevantes
- Las LSTM cuentan con más matrices, por lo que tienen más parámetros que una RNN normal, lo que hace más lento su entrenamiento



```
lstm (LSTM)
              (None, 128)
                           131584
             (None, 1)
dense 2 (Dense)
______
Total params: 1,411,713
Trainable params: 1,411,713
Non-trainable params: 0
Train on 17500 samples, validate on 7500 samples
Epoch 2/10
17500/17500 [===========] - 12s 667us/sample - loss: 0.2979 - accuracy: 0.8731
Epoch 3/10
17500/17500 [=============== ] - 12s 664us/sample - loss: 0.2044 - accuracy: 0.9183
Epoch 4/10
Epoch 6/10
Epoch 7/10
Epoch 8/10
Epoch 9/10
Epoch 10/10
In [20]: test_loss, test_acc = model.evaluate(x_test, y_test, verbose=2)
    print('\nTest acccuracy:', test_acc)
25000/1 - 3s - loss: 1.1409 - accuracy: 0.7889
Test acccuracy: 0.78892
In [21]: plt.figure(figsize=(10,9))
    plt.subplot(211)
    plt.plot(history.history['accuracy'])
    plt.plot(history.history['val_accuracy'])
    plt.title('accuracy')
    plt.legend(['train', 'test'])
    plt.grid()
    plt.subplot(212)
    plt.plot(history.history['loss'])
```

```
plt.plot(history.history['val_loss'])
plt.title('loss')
plt.legend(['train', 'test'])
plt.grid()
```



- Experimentar con diferentes arquitecturas y número de neuronas
- Experimentar con otro dataset
- Experimentar con otros optimizadores y funciones de activación