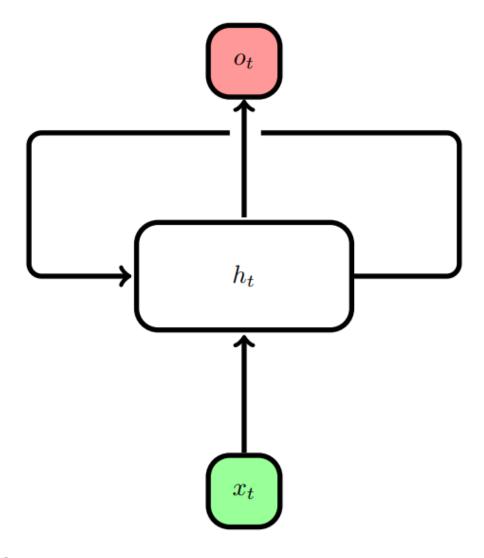
Análisis de Datos y Aprendizaje Máquina con Tensorflow 2.0: Redes neuronales recurrentes

2019/09/30

1 Estructura RNN

- Objetivo: Conocer la notación de las RNN
- Las redes recurrentes (RNN), son un tipo de red neuronal que procesa secuencialmente los datos, tomando en cuenta el estado oculto anterior h_{t-1} en la instancia de tiempo t
- Muchas RNN trabajan con embeddings en las entradas. Los embeddings son representaciones vectoriales aprendidas por la red, lo cual captura la relación de las palabras.
- A diferencia de los MLP, las RNN tienen memoria, es por eso que estas redes trabajan bien con secuencias de datos (el texto puede considerarse como una secuencia de datos)



```
In [1]: from tensorflow.keras.models import Model
from tensorflow.keras.layers import LSTM, Embedding, Dense, SimpleRNN
from tensorflow.keras.datasets import imdb
from tensorflow.keras.models import Sequential

from tensorflow.keras.preprocessing.sequence import pad_sequences
import matplotlib.pyplot as plt
```

2 Reseñas de películas de IMDB

- $\bullet\,$ Conjunto de datos de 25,000 críticas de películas de IMDB, etiquetadas por sentimiento (positivo / negativo).
- La función 'pad_sequences' recibe padding = 'post'/'pre' para agregar '0'. Por defecto se toma el parámetro 'pre'

```
https://www.tensorflow.org/guide/keras/masking_and_padding
```

```
In [2]: # numero de palabras
        num\_words = 4000
        max_len = 100
        (x_train, y_train), (x_test, y_test) = imdb.load_data(num_words=num_words)
        x_train = pad_sequences(x_train, maxlen=max_len, padding = 'post')
        x_test = pad_sequences(x_test, maxlen=max_len, padding = 'post')
        print(x_train.shape)
        print(x_test.shape)
        print(y_train.shape)
        print(y_test.shape)
(25000, 100)
(25000, 100)
(25000,)
(25000,)
In [3]: epoch = 10
        verbose = 1
        batch = 30
```

2.1 Cada palabra de la review esta identificada por un número

```
In [4]: print('Reseña')
       print(x_train[0])
       print('Etiqueta')
       print(y_train[0])
Reseña
[1415
       33
                22
                     12
                         215
                               28
                                   77
                                        52
                                                  14 407
                                                           16
                                                                82
            4 107 117
                                              2
                                                  7 3766
                                                               723
   2
        8
                           2
                              15
                                  256
                                         4
                                                            5
       71
            43 530 476
                                              7
  36
                          26
                              400
                                  317
                                        46
                                                  4
                                                       2 1029
                                                               13
 104
       88
            4
               381
                         297
                              98
                                   32 2071
                                             56
                                                  26
                                                     141
                                                               194
                     15
                                                            6
   2
       18
            4
               226
                     22
                          21
                              134
                                  476
                                        26
                                            480
                                                  5 144
                                                           30
                                                                 2
                28
                    224
                              25 104
                                            226
                                                           38 1334
  18
       51
            36
                          92
                                        4
                                                  65
                                                      16
  88
       12
            16 283
                    5
                        16 2 113 103
                                             32
                                                  15 16
                                                            2 19
 178
       32]
Etiqueta
```

2.2 Palabras de reseña

```
In [5]: wordDict = {y:x for x,y in imdb.get_word_index().items()}
    res = []
    for index in x_train[0]:
        res.append(wordDict.get(index - 3))
    print('Reseña: ',res,'Longitud reseña: ', len(res))
Reseña: ['cry', 'at', 'a', 'film', 'it', 'must', 'have', 'been', 'good', 'and', 'this', 'definit')
```

2.3 RNN simple con embedding

• Los embeddings son representaciones vectoriales de palabras o caracteres

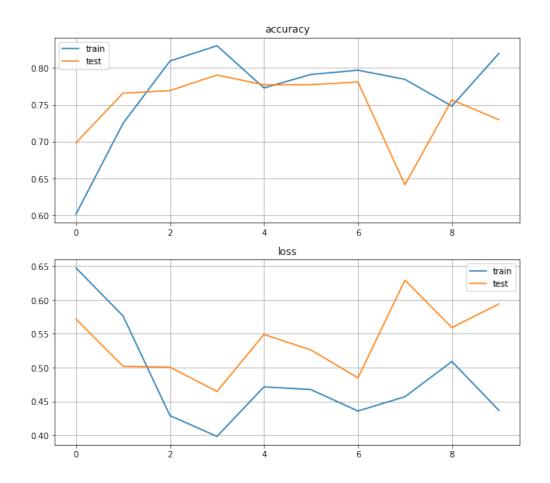
Model: "sequential"

Layer (type)	Output Shape	Param #
embedding (Embedding)	(None, None, 128)	512000
simple_rnn (SimpleRNN)	(None, 128)	32896
dense (Dense)	(None, 1)	129

Total params: 545,025 Trainable params: 545,025 Non-trainable params: 0

Train on 17500 samples, validate on 7500 samples

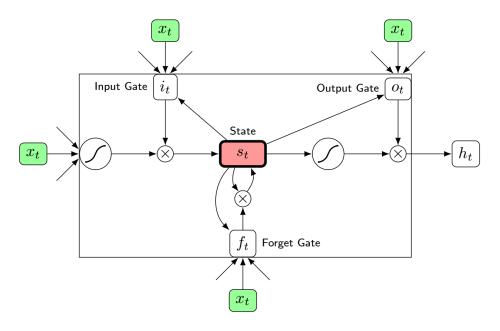
```
Epoch 6/10
Epoch 7/10
Epoch 8/10
Epoch 9/10
17500/17500 [============] - 26s 1ms/sample - loss: 0.5089 - accuracy: 0.7482 -
Epoch 10/10
In [8]: test_loss, test_acc = model.evaluate(x_test, y_test, verbose=2)
     print('\nTest acccuracy:', test_acc)
25000/1 - 7s - loss: 0.7967 - accuracy: 0.7376
Test acccuracy: 0.73756
In [9]: plt.figure(figsize=(10,9))
     plt.subplot(211)
     plt.plot(history.history['accuracy'])
     plt.plot(history.history['val_accuracy'])
     plt.title('accuracy')
     plt.legend(['train', 'test'])
     plt.grid()
     plt.subplot(212)
     plt.plot(history.history['loss'])
     plt.plot(history.history['val_loss'])
     plt.title('loss')
     plt.legend(['train', 'test'])
     plt.grid()
```



Test acccuracy: 0.73756

2.4 LSTM

- $\bullet\,$ En LSTM se toma en cuenta el estado $s_t,$ el cual sirve para olvidar o recordar elementos relevantes
- Las LSTM cuentan con más matrices, lo que les permite tener mejor memoria



```
In [11]: model = Sequential()
    model.add(Embedding(num_words, 128))
    model.add(LSTM(128))
    model.add(Dense(1, activation='sigmoid'))
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, None, 128)	512000
lstm (LSTM)	(None, 128)	131584
dense_1 (Dense)	(None, 1)	129

Total params: 643,713 Trainable params: 643,713 Non-trainable params: 0

Train on 17500 samples, validate on 7500 samples

Epoch 1/10

17500/17500 [==========] - 11s 628us/sample - loss: 0.4699 - accuracy: 0.7717

Epoch 2/10

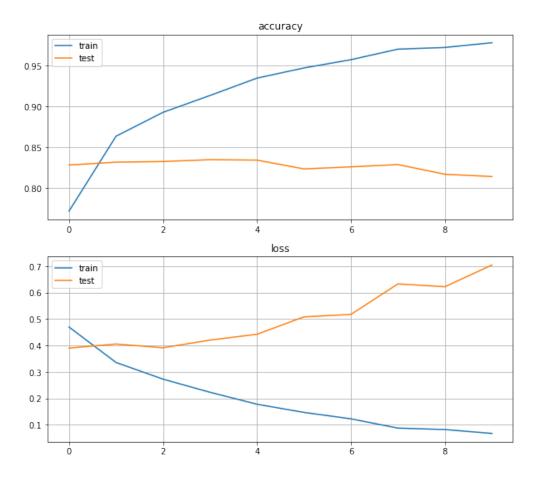
```
Epoch 3/10
Epoch 4/10
Epoch 5/10
Epoch 6/10
17500/17500 [===========] - 9s 507us/sample - loss: 0.1470 - accuracy: 0.9470
Epoch 7/10
17500/17500 [==============] - 9s 510us/sample - loss: 0.1226 - accuracy: 0.9571
Epoch 8/10
Epoch 9/10
Epoch 10/10
In [14]: plt.figure(figsize=(10,9))
    plt.subplot(211)
    plt.plot(history.history['accuracy'])
    plt.plot(history.history['val_accuracy'])
    plt.title('accuracy')
    plt.legend(['train', 'test'])
    plt.grid()
    plt.subplot(212)
    plt.plot(history.history['loss'])
```

plt.plot(history.history['val_loss'])

plt.legend(['train', 'test'])

plt.title('loss')

plt.grid()



Test acccuracy: 0.81608

- Experimentar con diferentes arquitecturas y número de neuronas
- Modificar el dataset para obtener mejores resultados
- Experimentar con otro dataset
- Experimentar con otros optimizadores y funciones de activación
- Nota: Los parámetros 'num_words' y 'maxlen' pueden dar como resultados diferentes entrenamientos, al modificar la estructura del dataset