Análisis de Datos y Aprendizaje Máquina con Tensorflow 2.0: Redes neuronales recurrentes

2019/09/30

Estructura RNN

- Objetivo: Conocer la notación de las RNN
- Las RNN con un tipo de red neuronal que puede trabajar con secuencias de datos al preservar el "estado" anterior
- Muchas RNN trabajan con embeddings en las entradas. Los embeddings son representaciones vectoriales aprendidas por la red, lo cual captura la relación de las palabras.
- A diferencia de las Feedforward neural networks, las RNN tienen memoria

```
In [1]: from tensorflow.keras.models import Model
    from tensorflow.keras.layers import LSTM, Embedding, Dense, SimpleRNN
    from tensorflow.keras.datasets import imdb
    from tensorflow.keras.models import Sequential

from tensorflow.keras.preprocessing.sequence import pad_sequences
    import matplotlib.pyplot as plt
```

Reseñas de películas de IMDB

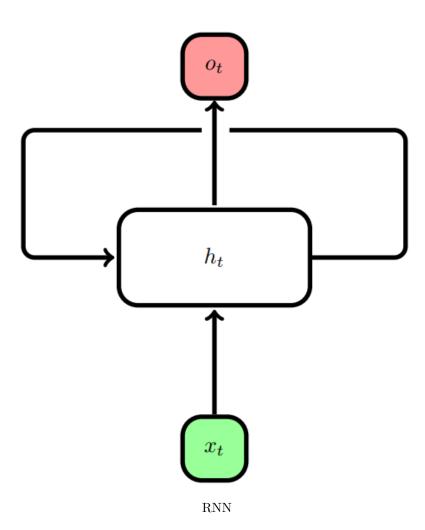
- Conjunto de datos de 25,000 críticas de películas de IMDB, etiquetadas por sentimiento (positivo / negativo).
- La función 'pad_sequences' recibe padding = 'post'/'pre' para agregar '0'. Por defecto se toma el parámetro 'pre'

https://www.tensorflow.org/guide/keras/masking_and_padding

```
In [2]: # numero de palabras
    num_words = 4000

max_len = 100

(x_train, y_train), (x_test, y_test) = imdb.load_data(num_words=num_words)
```



```
x_train = pad_sequences(x_train, maxlen=max_len, padding = 'post')
x_test = pad_sequences(x_test, maxlen=max_len, padding = 'post')

print(x_train.shape)
print(x_test.shape)
print(y_train.shape)
print(y_test.shape)

(25000, 100)
(25000, 100)
(25000,)
(25000,)
(25000,)
In [3]: epoch = 10
verbose = 1
batch = 30
```

Cada palabra de la review esta identificada por un número

```
In [4]: print('Reseña')
       print(x_train[0])
       print('Etiqueta')
       print(y_train[0])
Reseña
                                                        16
[1415
       33
            6
               22
                    12
                        215
                             28
                                  77
                                      52
                                            5
                                               14 407
                                                             82
   2
            4 107 117
                        2
                                 256
                                            2
                                                7 3766
                                                            723
       8
                             15
                                       4
                                                         5
           43 530 476
                                           7
  36
       71
                         26
                            400
                                 317
                                      46
                                                4
                                                   2 1029
                                                            13
 104
       88
            4 381
                    15 297
                             98
                                 32 2071
                                               26
                                                   141
                                                            194
                                           56
                                                         6
       18
           4 226
                    22
                         21 134 476
                                      26 480
                                               5 144
   2
                                                        30
                                                              2
                                      4 226
                                                        38 1334
  18
       51
           36
              28 224
                         92 25 104
                                               65 16
  88
       12
           16 283 5 16 2 113 103
                                          32
                                               15 16
 178
       321
Etiqueta
```

Palabras de reseña

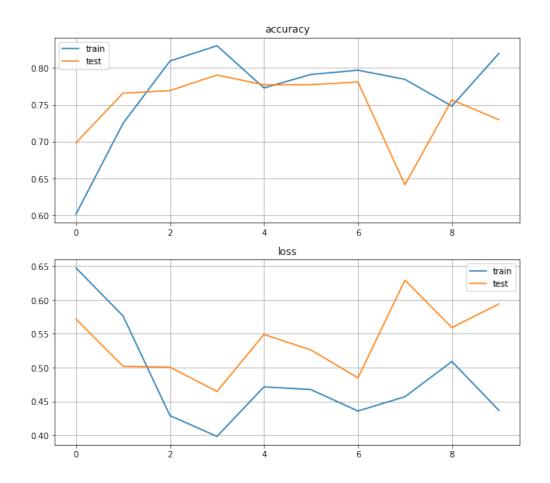
```
In [5]: wordDict = {y:x for x,y in imdb.get_word_index().items()}
    res = []
    for index in x_train[0]:
        res.append(wordDict.get(index - 3))
    print('Reseña: ',res,'Longitud reseña: ', len(res))
Reseña: ['cry', 'at', 'a', 'film', 'it', 'must', 'have', 'been', 'good', 'and', 'this', 'definit')
```

RNN simple con embedding

• Los embeddings son representaciones vectoriales de palabras o caracteres

```
In [6]: model = Sequential()
    model.add(Embedding(num_words, 128))
    model.add(SimpleRNN(128))
    model.add(Dense(1, activation='sigmoid'))
In [7]: model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
    model.summary()
    history = model.fit(x_train, y_train, batch_size=batch, epochs=epoch, verbose = verbose,
              validation_split = 0.3)
Model: "sequential"
                            Param #
Layer (type)
              Output Shape
_____
embedding (Embedding) (None, None, 128)
                          512000
simple_rnn (SimpleRNN) (None, 128)
                            32896
dense (Dense) (None, 1) 129
_____
Total params: 545,025
Trainable params: 545,025
Non-trainable params: 0
Train on 17500 samples, validate on 7500 samples
Epoch 1/10
Epoch 2/10
Epoch 3/10
17500/17500 [=============== ] - 27s 2ms/sample - loss: 0.4288 - accuracy: 0.8096 -
Epoch 4/10
Epoch 5/10
17500/17500 [============== ] - 27s 2ms/sample - loss: 0.4714 - accuracy: 0.7730 -
Epoch 6/10
Epoch 7/10
Epoch 8/10
Epoch 9/10
Epoch 10/10
17500/17500 [============] - 27s 2ms/sample - loss: 0.4366 - accuracy: 0.8199 -
```

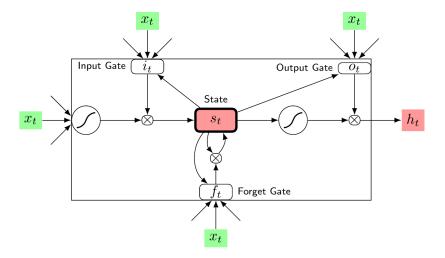
```
In [8]: test_loss, test_acc = model.evaluate(x_test, y_test, verbose=2)
        print('\nTest acccuracy:', test_acc)
25000/1 - 7s - loss: 0.7967 - accuracy: 0.7376
Test acccuracy: 0.73756
In [9]: plt.figure(figsize=(10,9))
        plt.subplot(211)
        plt.plot(history.history['accuracy'])
        plt.plot(history.history['val_accuracy'])
        plt.title('accuracy')
        plt.legend(['train', 'test'])
       plt.grid()
        plt.subplot(212)
        plt.plot(history.history['loss'])
        plt.plot(history.history['val_loss'])
        plt.title('loss')
        plt.legend(['train', 'test'])
        plt.grid()
```



Test acccuracy: 0.73756

LSTM

- $\bullet\,$ En LSTM se toma en cuenta el estado st, el cual sirve para olvidar o recordar parámetros relevantes
- Las LSTM cuentan con más matrices, lo que les permite tener mejor memoria



validation_split = 0.3)

Model: "sequential_1"

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, None, 128)	512000
lstm (LSTM)	(None, 128)	131584
dense_1 (Dense)	(None, 1)	129

Total params: 643,713 Trainable params: 643,713 Non-trainable params: 0

```
Train on 17500 samples, validate on 7500 samples
```

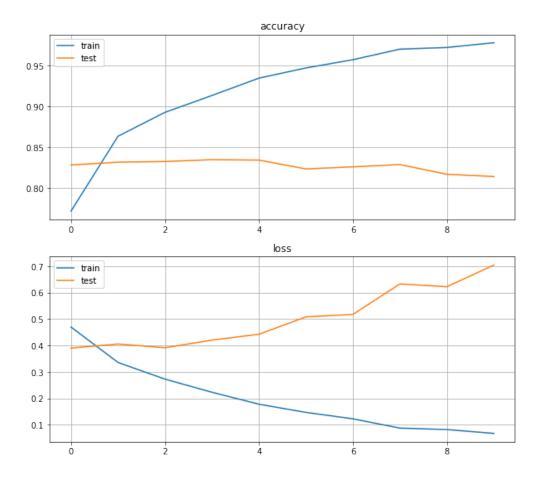
Epoch 1/10

Epoch 3/10

17500/17500 [==========] - 9s 516us/sample - loss: 0.2728 - accuracy: 0.8926 Epoch 4/10

```
Epoch 5/10
Epoch 6/10
Epoch 7/10
Epoch 8/10
17500/17500 [===========] - 9s 518us/sample - loss: 0.0876 - accuracy: 0.9700
Epoch 9/10
17500/17500 [==============] - 9s 522us/sample - loss: 0.0820 - accuracy: 0.9721
Epoch 10/10
17500/17500 [===========] - 9s 507us/sample - loss: 0.0674 - accuracy: 0.9779
In [14]: plt.figure(figsize=(10,9))
     plt.subplot(211)
     plt.plot(history.history['accuracy'])
     plt.plot(history.history['val_accuracy'])
     plt.title('accuracy')
     plt.legend(['train', 'test'])
     plt.grid()
     plt.subplot(212)
     plt.plot(history.history['loss'])
     plt.plot(history.history['val_loss'])
     plt.title('loss')
     plt.legend(['train', 'test'])
```

plt.grid()



Test acccuracy: 0.81608

- Experimentar con diferentes arquitecturas y número de neuronas
- ullet Experimentar con otro dataset
- Experimentar con otros optimizadores y funciones de activación